



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 1

Relación entre establecimientos educativos y actividades productivas en Argentina

23 de octubre de 2025

Laboratorio de Datos

burritodiabolico

Integrante	LU	Correo electrónico
Faltlhauser, Andres	1255/24	faltlhauserandres@gmail.com
Kirschbaum, Owen	1310/24	owenkir17@gmail.com
Yurzola, Marcos	1235/24	myurzol@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (++54 +11) 4576-3300

<http://www.exactas.uba.ar>

1. Resumen

Este trabajo explora la relación entre la infraestructura de establecimientos educativos (EE) y la actividad de establecimientos productivos (EP) en Argentina, utilizando datos públicos de los padrones de educación, producción y población del año 2022.

El proyecto comenzó con un riguroso proceso de calidad y normalización de datos. Los datasets originales presentaban problemas de calidad (datos faltantes) y estructurales (violaciones de la Primera y Segunda Forma Normal). Para solucionar esto, se aplicó un proceso de extracción, selección y transformación que resultó en un modelo de datos relacional normalizado (3FN), listo para el análisis.

El análisis de datos se centró en una serie de visualizaciones para comparar las variables. Se generaron gráficos de distribución (barras y boxplots) que revelaron la alta concentración de la actividad económica y educativa en unos pocos departamentos urbanos. Posteriormente, se analizaron las relaciones entre la oferta educativa y la demanda poblacional, y se examinaron segmentos específicos como la segregación de género en el empleo.

El análisis concluyente, que comparó la densidad de empleo contra la densidad de establecimientos (ambos normalizados por cada 1.000 habitantes), refutó la hipótesis inicial. Los resultados demuestran que no existe una correlación lineal simple entre más escuelas y más empleo. La relación está mediada por la densidad poblacional: los grandes centros urbanos concentran la mayor tasa de empleo por cápita pero requieren menos establecimientos educativos por cápita (debido a la eficiencia y las economías de escala), mientras que en las zonas rurales ocurre lo contrario.

2. Introducción

Desde diversas áreas del conocimiento se ha propuesto que la educación está íntimamente relacionada al desarrollo productivo de una sociedad. Esta afirmación ha sido sostenida por innumerables fuentes de datos y análisis, partiendo de la premisa de que una fuerza laboral más instruida genera mayor innovación y productividad.

El objetivo del presente trabajo es explorar si en Argentina existe una relación empírica y visible entre la presencia de infraestructura educativa y el desarrollo de actividades productivas a nivel local. Para ello, se busca responder a la pregunta: ¿Las regiones con mayor cantidad de establecimientos educativos (EE) coinciden con aquellas que tienen una mayor cantidad de establecimientos productivos (EP) y, por ende, más empleo?

Para llevar a cabo esta exploración, se utilizaron tres fuentes de datos abiertos provistas por el Gobierno de la República Argentina:

- Establecimientos Educativos (EE): Padrón Oficial del año 2022.
- Establecimientos Productivos (EP): Padrón de Establecimientos Productivos, incluyendo datos de empleo por género y actividad económica (CLAE6).
- Población: Datos del Censo 2022, desagregados por departamento y edad.

El informe se estructura en varias etapas. En primer lugar, se detalla el proceso fundamental de Procesamiento y Calidad de Datos, donde se analizó el estado de los datasets originales y se realizó una normalización (llevándolos a la Tercera Forma Normal) para garantizar la integridad del análisis. A continuación, en la sección de Análisis de Datos, se presentan las visualizaciones generadas para comparar estas variables, desde distribuciones geográficas hasta análisis de ratios normalizados por población. Finalmente, se presenta una Conclusión que sintetiza los hallazgos y da una respuesta a la pregunta de investigación inicial.

3. Procesamiento de Datos

Análisis de Calidad y Formas Normales

3.1. Tabla: Establecimientos Educativos

3.1.1. Análisis de Formas Normales

- Forma Normal: La tabla original de Establecimientos Educativos no se encuentra en Primera Forma Normal (1FN).
- Justificación: Una tabla está en 1FN si todos sus atributos son atómicos, es decir, contienen un solo valor y no hay grupos repetitivos. Esta tabla viola esa regla al tener múltiples columnas para representar un único concepto: el nivel educativo (Nivel inicial - Jardín maternal, Nivel inicial - Jardín de infantes, Primario, Secundario, etc.). Esto se conoce como un "grupo repetitivo" y es una clara violación de la atomicidad de los datos.

3.1.2. Revisión de Calidad de Datos (GQM)

Se identificó un problema de completitud en los datos de contacto de los establecimientos.

- Problema de Calidad: Ausencia de datos de contacto (dirección de mail).
- Atributo de Calidad Afectado: Completitud. Este atributo se refiere a que estén presentes todos los valores necesarios para representar la realidad.
- Tipo de Problema: Se trata de un problema de instancia. El modelo de datos contempla el campo Mail, pero los valores no fueron cargados en una gran cantidad de registros o instancias.
- Medición con Técnica GQM:
 - **Goal** (Objetivo): Asegurar que la información de contacto de los establecimientos educativos esté lo más completa posible para permitir una comunicación efectiva.
 - **Question** (Pregunta): ¿Qué proporción de los establecimientos educativos en el padrón carece de una dirección de correo electrónico registrada?
 - **Metric** (Métrica):

$$M1 = \frac{\text{Número de registros con el campo 'Mail' vacío}}{\text{Número total de registros}}$$

- Valores Obtenidos en la Métrica:
 - Total de registros analizados: 115,581
 - Cantidad de registros con el campo "Mail" vacío o nulo: 49,853
 - Porcentaje de registros sin email (Valor de la Métrica): 43.13
- Diagnóstico y Acciones de Mejora:
 - **Diagnóstico:** La falta de más de un tercio de las direcciones de correo electrónico es un problema de calidad de datos severo que limita la utilidad del padrón como herramienta de comunicación. Las causas pueden ser la falta de obligatoriedad en la carga del dato o procesos de actualización deficientes.
 - **Acción de Mejora:** No es posible corregir este problema directamente sin información externa. La acción de mejora recomendada es preventiva: modificar el proceso de carga de datos para que el campo Mail sea obligatorio o, al menos, se valide su formato. A nivel correctivo, se podría iniciar una campaña de recolección de datos para completar los registros faltantes.

3.2. Tabla: Establecimientos Productivos

3.2.1. Análisis de Formas Normales

- Forma Normal: La tabla de Establecimientos Productivos (del archivo *Datos_por_departamento_actividad_y_sex*) se encuentra en 1FN, pero no en 2FN y por lo tanto, tampoco en 3FN.
- Justificación:
 - **Cumple 1FN:** Todos los valores de sus columnas son atómicos.
 - **No Cumple 2FN:** La clave primaria de esta tabla es una clave compuesta por (*anio*, *in_departamentos*, *clae6*, *genero*). Sin embargo, existen atributos que dependen solo de una parte de esa clave. Por ejemplo, *departamento* y *provincia* dependen únicamente de *in_departamentos*, no de la clave completa. Esto es una dependencia parcial, lo cual viola la 2FN.
 - **No Cumple 3FN:** Adicionalmente, existen dependencias transitivas. El atributo *provincia* depende de *provincia_id* (que a su vez depende de *in_departamentos*), lo cual viola la 3FN.

3.2.2. Revisión de Calidad de Datos (GQM)

Se ha identificado un problema de consistencia lógica entre la cantidad de establecimientos y el empleo reportado.

- Problema de Calidad: Registros con empleo positivo pero cero establecimientos.
- Atributo de Calidad Afectado: Consistencia y Corrección. Un dato es consistente cuando no entra en contradicción con otro dato, y es correcto si representa la situación real. Es lógicamente inconsistente e incorrecto tener empleados sin un establecimiento que los emplee.
- Tipo de Problema: Se trata de un problema originado en los procesos. Probablemente, el software o el proceso automatizado que agrega y consolida estos datos contiene errores que llevan a estas inconsistencias.
- Medición con Técnica GQM:
 - **Goal** (Objetivo): Asegurar que los datos de actividad productiva sean lógicamente consistentes, de modo que el empleo reportado siempre corresponda a una cantidad no nula de establecimientos.
 - **Question** (Pregunta): ¿Qué proporción de los registros de actividad productiva muestra una cantidad de empleo mayor a cero cuando el número de establecimientos es igual a cero?
 - **Metric** (Métrica):

$$M1 = \frac{\text{Número de registros donde (Empleo > 0 Y Establecimientos = 0)}}{\text{Número total de registros}}$$

- Valores Obtenidos en la Métrica:
 - Total de registros analizados: 643,348
 - Cantidad de registros inconsistentes: 10,753
 - Porcentaje de registros inconsistentes (Valor de la Métrica): 1.6715
- Diagnóstico y Acciones de Mejora:
 - **Diagnóstico:** Este resultado cuantifica el problema de consistencia y corrección en los datos. Aunque el porcentaje es relativamente bajo (menos del 2 %), el número absoluto de más de 10,000 registros con este error lógico es significativo y justifica plenamente la decisión de limpiar los datos antes del análisis.
 - **Acción de Mejora:** La acción principal es reportar el hallazgo a los dueños de los datos para que revisen sus procesos de obtención y carga de los mismos. Para el propósito de este análisis, una acción de corrección viable sería filtrar y excluir estos registros inconsistentes, documentando claramente esta decisión en el informe para no sesgar los resultados de análisis posteriores.




Figura 1: Diagrama Entidad Relación de las bases de datos.

3.2.4. Modelo Relacional y Dependencias funcionales




Figura 2: Modelo Relacional y Dependencias Funcionales.

Explicación de Claves Principales y Foráneas

La tabla **Departamentos** es el centro de los datos, ya que la mayoría se relacionan a partir de `id_departamento`:

- `Departamentos.id_provincia` (FK) se conecta con `Provincias.id` (PK).
- `Padron_Poblacion.id_departamento` (FK) se conecta con `Departamentos.id_departamento` (PK).
- `Establecimientos_Educativos.id_departamento` (FK) se conecta con `Departamentos.id_departamento` (PK).
- `Dep_Act_Sex.id_departamento` (FK) se conecta con `Departamentos.id_departamento` (PK).

La tabla **Dep_Act_Sex** se conecta con la tabla de actividades (**Actividades_Establecimientos**). Esto significa que muchos registros de empleo usan 1 código de actividad (CLAE).

- `Dep_Act_Sex.clae6` (FK) se conecta con `Actividades_Establecimientos.clae6` (PK).

Luego la tabla **Niveles_EE** nos permite crear una relación **muchos a muchos** entre los Establecimientos y los Niveles. Permite que un Establecimiento pueda tener múltiples niveles, y que un nivel pueda estar en múltiples Establecimientos:

- `Niveles_EE.Cueanexo` (FK) se conecta con `Establecimientos_Educativos.Cueanexo` (PK).
- `Niveles_EE.id_nivel` (FK) se conecta con `Tipos_Niveles.id` (PK).

4. Decisiones tomadas

Durante las etapas de procesamiento, limpieza y análisis, fue necesario tomar una serie de decisiones metodológicas para garantizar la calidad e integridad de los datos y la correcta interpretación de los resultados. A continuación, se detallan las más relevantes.

4.1. Normalización del Modelo de Datos

La decisión más importante del trabajo fue no utilizar los archivos originales para el análisis, sino procesarlos y llevarlos a la Tercera Forma Normal (3FN). Los datasets originales presentaban problemas estructurales que impedían un análisis confiable:

- **Establecimientos Educativos:** Violaba la 1FN al presentar los niveles educativos como columnas (un grupo repetitivo).
- **Establecimientos Productivos:** Violaba la 2FN y 3FN al repetir datos de provincias y departamentos en cada registro, generando alta redundancia.

Decisión: Se descompusieron los archivos en un modelo de datos en estrella (ver DER), creando tablas de dimensiones (*Provincias*, *Departamentos*, *Tipos_Niveles*, etc.) y tablas de hechos (*Dep_Act_Sex*, *Establecimientos_Educativos*). Justificación: Esta decisión eliminó la redundancia, aseguró la consistencia de los datos (ej. "Buenos Aires" se escribe de una sola forma) y previno futuras anomalías de actualización.

4.2. Estandarización de Identificadores Geográficos

Los datasets originales no compartían un sistema unificado de códigos de departamento, especialmente para las Comunas de CABA. Decisión: Se creó una tabla maestra (*Departamentos.csv*) unificando los códigos de los tres archivos fuente. Esto implicó un proceso de data wrangling para mapear los distintos identificadores (ej. los códigos 2101-2115 de CABA en el padrón educativo) a un único código maestro. Justificación: Sin esta estandarización, habría sido imposible cruzar los datos de población, educación y empleo a nivel departamental.


4.3. Imputación de Datos Faltantes

Al procesar los datos de empleo (*df3*) para pivotar los géneros de filas a columnas, se generaron valores nulos (NaN) en los casos donde una actividad tenía empleo de un solo género (ej. 100 % mujeres, NaN en varones). Decisión: Se decidió imputar estos valores faltantes (NaN) por un cero (0). Justificación: En este contexto, un valor NaN no significaba "desconocido", sino "ausencia de registro", lo cual es funcionalmente equivalente a cero empleados para ese género en esa actividad.

5. Análisis de Datos

5.1. Visualización


5.1.1.



En este gráfico de barras se representa la cantidad total de empleados registrados por provincia durante el año 2022, ordenados de manera decreciente. Se observa una marcada concentración del empleo en unas pocas provincias. La provincia de Buenos Aires lidera con una gran diferencia, superando los 5.7 millones de empleados. Le siguen CABA (3.1M), Córdoba (1.4M) y Santa Fe (1.3M). Existe una brecha muy significativa entre este grupo de cuatro provincias y el resto del país. Por ejemplo, Mendoza, la quinta provincia, ya presenta menos de la mitad de empleados que Santa Fe. La cola del gráfico es larga, con 12 provincias que no alcanzan los 200,000 empleados.

Reflexión: Este gráfico es fundamental para contextualizar el resto del análisis. Demuestra visualmente la heterogeneidad económica y demográfica de Argentina. La estructura productiva del país está fuertemente centralizada en la región pampeana y CABA.

5.1.2.




Este gráfico de dispersión compara la oferta de establecimientos educativos (Eje Y) contra la "demanda", medida como la población en el grupo etario correspondiente (Eje X). Cada departamento del país está repre-

sentado tres veces en el gráfico: un punto rojo para el nivel inicial (0-5 años), uno azul para el primario (6-12 años) y uno verde para el secundario (13-17 años).

Se observa una fuerte correlación positiva en los tres niveles. Los puntos forman "nubes" que ascienden de izquierda a derecha, indicando que a medida que aumenta la población de un grupo etario en un departamento, también lo hace la cantidad de establecimientos de ese nivel. La mayoría de los departamentos se agrupan en la esquina inferior izquierda (baja población, pocas escuelas), mientras que unos pocos departamentos muy poblados (los outliers a la derecha) muestran una cantidad de establecimientos proporcionalmente alta.

Reflexión: Esta visualización confirma de manera contundente la hipótesis de que la distribución de la infraestructura educativa sigue, en gran medida, a la distribución demográfica. La oferta de escuelas no es aleatoria, sino que responde directamente a la demanda poblacional.

5.1.3.




Este diagrama de cajas (boxplot) muestra la distribución de la cantidad de establecimientos educativos por departamento, agrupados por provincia. El eje X utiliza una escala logarítmica para poder observar adecuadamente la gran disparidad de valores. Las provincias están ordenadas por su mediana (la línea vertical dentro de la caja), de mayor a menor (arriba hacia abajo).

Se pueden identificar dos patrones claros:

1. **Provincias Homogéneas:** provincias como Tierra del Fuego, La Pampa y, notablemente, CABA, presentan cajas muy cortas. Esto indica que todos sus departamentos (o comunas, en el caso de CABA) tienen una cantidad de escuelas muy similar entre sí.
2. **Provincias Heterogéneas:** provincias como Buenos Aires, Santa Fe, Córdoba y Misiones muestran cajas muy "largas", fundamentalmente, una gran cantidad de puntos outliers (valores atípicos).

Reflexión: Este gráfico revela la desigualdad interna de la infraestructura educativa dentro de cada provincia. Mientras que el Gráfico 1 mostraba la diferencia entre provincias, este muestra la diferencia dentro de ellas. El caso de Buenos Aires es el más extremo: su mediana se sitúa alrededor de las 150 escuelas, pero posee numerosos departamentos (los puntos outliers) que superan los 500 o 1.000 establecimientos. Esto refleja una alta concentración en el conurbano bonaerense en detrimento de los departamentos del interior de la provincia. Por el contrario, CABA es perfectamente homogénea: todas sus comunas son grandes y tienen una cantidad de escuelas similar y muy elevada (mediana de 700-800).

5.1.4.



Este gráfico de dispersión es el análisis central del trabajo, ya que compara la densidad de empleo (Eje Y: Empleados cada 1000 hab.) con la densidad de infraestructura educativa (Eje X: EE cada 1000 hab.) para cada departamento. Al normalizar los datos por población, eliminamos el sesgo del tamaño y podemos comparar departamentos de forma justa. El color y tamaño de cada burbuja indican la población total del departamento, desde los menos poblados (azul oscuro, pequeños) hasta los más poblados (amarillo, grandes).


A simple vista, no existe una correlación lineal ya que los puntos forman una nube dispersa. Sin embargo, al observar los colores, si se puede idear un patrón:

- **Departamentos más poblados** (burbujas amarillas): Se agrupan casi exclusivamente en la esquina inferior derecha. Tienen una baja tasa de escuelas por habitante ($X < 5$) pero una alta tasa de empleo por habitante ($Y > 200$).
- **Departamentos menos poblados** (burbujas azul oscuro): Están esparcidos por todo el gráfico. Notablemente, son los únicos que ocupan el extremo derecho del gráfico, mostrando tasas de escuelas por habitante muy altas ($X > 10$).

Reflexion: Este gráfico revela dos dinámicas fundamentales: la “eficiencia” de los establecimientos y la concentración económica.

- **Eficiencia de la Infraestructura** (Establecimientos Educativos): Los departamentos más poblados (amarillos) son eficientes. Se podría suponer que necesitan menos escuelas por cada 1000 habitantes porque construyen establecimientos más grandes que sirven a miles de estudiantes. Por el contrario, los departamentos rurales y poco poblados (azules) son ineficientes.^{en} este ratio: para dar servicio a la misma cantidad de niños, pero esparcidos en un territorio amplio, necesitan muchas escuelas pequeñas, disparando su ratio de “EE cada 1000 hab.”
- **Concentración Económica:** Los mismos departamentos urbanos (amarillos) son los grandes centros de empleo del país. Su alta tasa de .Empleados cada 1000 hab.”demuestra que son centros económicos que concentran la actividad productiva.

5.1.5.



Este gráfico de barras muestra las 10 actividades económicas (CLAE6) con las proporciones más extremas de empleo femenino en 2022. Las 5 actividades con mayor proporción de mujeres se muestran en verde (Top 5) y las 5 con menor proporción en rojo (Bottom 5). Adicionalmente, una línea azul punteada marca el promedio general de empleo femenino en toda la economía (44.4%). Se observa una segregación de género muy marcada.

- **Top 5 (Verdes):** Las actividades con mayor presencia femenina superan el 85 % de empleo femenino. Estas están casi exclusivamente ligadas a tareas de cuidado ("Guarderías y Jardines maternos", "Venta al por menor de indumentaria para bebés"), salud ("Servicios Odontológicos") y servicios personales.
- **Bottom 5 (Rojas):** Las actividades con menor presencia femenina tienen proporciones por debajo del 4 %. Estas están ligadas a la industria pesada ("Fabricación de tractores") y servicios de transporte (ferroviarios de carga, automotor urbano y suburbano, automotor de cereales).

Reflexión: Este gráfico es una radiografía de la segregación laboral por género. El promedio general del 44.4 % es engañoso, ya que sugiere una paridad que no existe a nivel micro. La realidad es que la economía está compuesta por sectores fuertemente feminizados (generalmente ligados a roles de cuidado y peor remunerados) y sectores fuertemente masculinizados (ligados a la industria y la construcción). Esta división estructural es un factor clave para entender las dinámicas sociales y económicas del país, y podría ser un punto de partida para análisis futuros sobre la correlación entre la oferta educativa y estas salidas laborales segregadas.

6. Conclusiones

El objetivo central de este trabajo práctico fue explorar si existe una relación entre la presencia de establecimientos educativos y el desarrollo de actividades productivas en Argentina. Para responder a esta pregunta, se realizó un profundo proceso de limpieza, normalización y análisis de los padrones de establecimientos, empleo y población.

El primer desafío encontrado fue la calidad y estructura de los datos originales. Los datasets no se encontraban en formas normales (violando 1FN y 2FN) y presentaban problemas de calidad de datos, como valores faltantes e inconsistencias lógicas. Mediante la limpieza de los datos, los datasets fueron pasados a 3FN, garantizando la calidad necesaria para un análisis robusto.

Al analizar los datos, la primera observación fue la extrema concentración económica y demográfica. Unas pocas Provincias (Buenos Aires, CABA, Córdoba y Santa Fe) concentran la gran mayoría tanto del empleo total como de la infraestructura educativa. Asimismo, el análisis de distribución interna (boxplot) reveló que esta concentración se repite dentro de las provincias, donde los departamentos capitales y las grandes zonas urbanas acumulan mayor cantidad de establecimientos en comparación a los departamentos rurales.

Sin embargo, el hallazgo más significativo provino del análisis de las métricas normalizadas por población (Gráfico 4: Empleados cada 1000 hab. vs. EE cada 1000 hab.). Este gráfico demostró que la hipótesis inicial de una correlación lineal simple (más escuelas = más empleo) no se sostiene.

En su lugar, se reveló una relación más compleja que depende de dos factores clave: la densidad poblacional y la urbanización:

- **Departamentos Urbanos (alta población):** Estos departamentos (las burbujas amarillas del gráfico) funcionan como los motores económicos del país, presentando la mayor tasa de empleo por habitante. Paradójicamente, son los que tienen la menor tasa de establecimientos educativos por habitante.
- **Departamentos Rurales (baja población):** Estos departamentos (azules) muestran una baja tasa de empleo y, a la vez, una tasa de establecimientos educativos por habitante muy alta.

Esta contradicción se explica por las economías de escala. Las grandes ciudades son más eficientes: necesitan menos edificios escolares per cápita, ya que construyen establecimientos más grandes que dan servicio a mayor cantidad de personas. En las zonas rurales, se necesita una mayor cantidad de establecimientos per cápita (escuelas pequeñas y distribuidas) para poder garantizar la cobertura de una población dispersa en el territorio.

En conclusión, la relación entre la infraestructura educativa y la producción no es directa. La presencia de una alta densidad de establecimientos educativos por habitante no se correlaciona con una alta actividad productiva; de hecho, suele ser un indicador de ruralidad porque en este tipo de zonas dichos establecimientos educativos son menos “eficientes” (Se requiere de más establecimientos ya que son más pequeños y tienen menor capacidad). La actividad productiva, en cambio, se concentra en los grandes centros urbanos que, por eficiencia, requieren una menor cantidad de establecimientos por cápita.

Fuentes de datos

Los datos utilizados en este trabajo:

- **Establecimientos Educativos (EE). Padrón Oficial de Establecimientos Educativos del año 2022.:**
<https://www.argentina.gob.ar/educacion/evaluacion-e-informacion-educativa/padron-oficial-de-establecimientos-educativos>
- **Establecimientos Productivos (EP). Padrón de Establecimientos Productivos.:**
<https://datos.produccion.gob.ar/dataset/distribucion-geografica-de-los-establecimientos-productivos/archivo/16f0dfc2-a9ff-4696-b2e5-79831c5c0ec4>
- **Establecimientos Productivos (EP). Actividades.:**
<https://datos.produccion.gob.ar/dataset/distribucion-geografica-de-los-establecimientos-productivos/archivo/d8ca32fa-a523-4583-96cc-97e4d21467aa>
- **Población. Datos de población por Departamento del censo 2022.:**
<https://www.indec.gob.ar/indec/web/Nivel4-Tema-2-41-165>